

**Федеральное государственное автономное образовательное учреждение
высшего образования
«Национальный исследовательский ядерный университет «МИФИ»**

ОТЧЕТ

по лабораторной работе №1 (вариант 42)
по дисциплине: «Математическая статистика и машинное обучение»

Выполнил: *студент группы Б24-215*

Гаганидзе Г. Г.

(подпись)

(Фамилия И.О.)

Проверил:

Смирнов Д. С.

(оценка)

(подпись)

(Фамилия И.О.)

Москва 2026 г.

Содержание

Введение	2
1 Методология исследования	4
1.1 Метод идеальной точки	4
1.2 Формирование выборки и методы отбора	4
1.3 Оценка точности и надежности результатов	6
1.4 Оценка и обоснование объема выборки	8
1.5 Методика проверки статистической несмещенности на основе Z-критерия	9
2 Реализация	12
2.1 Используемые библиотеки	12
2.2 Загрузка и предобработка данных	12
2.3 Вычисление интегральных показателей по модели идеальной точки	13
2.4 Реализация методов отбора	13
2.5 Оценка дисперсий разведочной выборки	16
3 Результаты исследования	17
3.1 Результаты разведочного анализа	17
3.2 Анализ устойчивости на малых выборках	17
3.3 Минимальный объем выборки и точность	18
3.4 Имитационное моделирование	19
3.4.1 Устойчивость определения лидера	19
3.4.2 Усредненные оценки и вариативность	20
3.4.3 Проверка статистической несмещенности	21
3.5 Визуализация и интерпретация	22
Заключение	24
Список литературы	25

Введение

В современных маркетинговых исследованиях и анализе данных ключевым этапом является сбор репрезентативной информации о предпочтениях потребителей. В условиях ограниченности ресурсов проведение сплошного опроса генеральной совокупности зачастую невозможно, что обуславливает актуальность применения различных методов выборочного наблюдения.

Актуальность работы заключается в необходимости поиска наиболее точных и эффективных алгоритмов формирования выборки, которые позволяют минимизировать статистическую погрешность при оценке потребительских качеств товаров и брендов.

Объектом исследования является массив данных опроса респондентов, содержащий оценки характеристик ведущих аудио-брендов (Sony, JBL, Marshall) по различным критериям (качество звука, цена, дизайн и др.).

Предметом исследования выступают методы статистического отбора и их влияние на точность оценки лояльности потребителей в рамках модели идеальной точки.

Целью данной работы является проведение сравнительного анализа алгоритмов статистического отбора и обоснование выбора оптимальной методики формирования выборки, обеспечивающей максимальную репрезентативность данных и устойчивость интегральных показателей потребительской лояльности.

Для достижения поставленной цели необходимо решить следующие **задачи**:

1. Осуществить предварительную **обработку данных** генеральной совокупности респондентов.
2. Реализовать алгоритмически 4 метода отбора данных: *случайный, механический, типический и кластерный*.
3. Вычислить **интегральный показатель брендов**, используя модель *идеальной точки*, учитывающую веса параметров и ожидания потребителей.
4. Провести статистическую оценку **репрезентативности** полученных выборок.

5. Сравнить **эффективность методов** отбора на основе полученных показателей точности и визуализировать результаты анализа.

Практическая значимость работы заключается в разработке инструментария на языке *Python*, который автоматизирует расчет рейтингов брендов и их погрешностей. Созданный программный код наглядно демонстрирует разные методы отбора данных и позволяет выбрать тот, который дает наиболее точный результат с минимальной ошибкой.

1. Методология исследования

В данном разделе описывается математический аппарат и алгоритмическая последовательность действий, использованных для проведения статистического анализа и оценки характеристик брендов...

1.1. Метод идеальной точки

Для количественной оценки потребительских предпочтений в работе используется *модель идеальной точки*. Данный метод позволяет оценить степень близости реальных характеристик товара к ожиданиям потребителя. Расчет итогового балла бренда (A_b) производится по формуле:

$$A_b = \sum_{i=1}^m W_i \cdot |I_i - X_i|, \quad (1)$$

где

m — количество параметров,

W_i — коэффициент важности i -го параметра,

I_i — значение i -го параметра для «идеального» продукта,

X_i — фактическое значение i -го параметра оцениваемого бренда.

Чем ниже полученное значение A_b , тем выше лояльность потребителя к бренду, так как его характеристики ближе к идеальным.

1.2. Формирование выборки и методы отбора

Центральной задачей работы является сравнение эффективности различных методов формирования выборки из генеральной совокупности (данных опроса респондентов). Были реализованы следующие алгоритмы:

1. Собственно-случайный отбор (Simple Random Sampling)

Базовый метод статистического исследования, основанный на принципе равновероятности включения любого элемента генеральной совокупности в выборку. Метод минимизирует систематическую ошибку исследователя и используется в качестве контрольного уровня для оценки

статистической эффективности других алгоритмов. В данной работе реализована модель *бесповторного* и *повторного* отбора.

2. Механический отбор (Mechanical Sampling)

Систематический метод, предполагающий отбор единиц из упорядоченного массива данных через равные интервалы. Метод эффективен при отсутствии периодических закономерностей в исходном массиве, которые могли бы совпасть с шагом отбора и исказить результаты. Такой метод отбора подразумевает только *бесповторный* способ.

3. Типический отбор (Stratified Sampling)

Метод, основанный на предварительном разделении (стратификации) неоднородной совокупности на качественно однородные страты по заданному признаку¹. В рамках исследования выборка формируется путем случайного отбора из каждой страты пропорционально их доле в генеральной совокупности. Данный подход позволяет существенно снизить стандартную ошибку средней за счет исключения межгрупповой дисперсии из общей ошибки выборки. В данной работе реализована модель *бесповторного* и *повторного* отбора.

4. Кластерный отбор (Cluster Sampling)

Метод формирования выборки, при котором объектом отбора выступают не отдельные респонденты, а их логические или структурные группы — кластеры². Выборка формируется путем случайного отбора самих серий, внутри которых проводится сплошное обследование. Использование данного метода в работе позволяет проанализировать устойчивость оценок брендов с учетом внутригрупповой корреляции и оценить влияние специфических характеристик конкретных групп данных на итоговый интегральный признак. В данной работе реализована модель *бесповторного* и *повторного* отбора.

¹ В работе применялась поло-возрастная стратификация.

² Деление на кластеры в работе происходило по географическому признаку.

1.3. Оценка точности и надежности результатов

Для того чтобы полученные результаты были *репрезентативными* (т.е. адекватно воспроизводили структуру генеральной совокупности), в работе проводится расчет следующих показателей:

1. **Выборочная средняя оценка** — среднее арифметическое значений всех объектов в выборке, выступающее в роли точечной оценки генерального среднего значения:

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i, \quad (2)$$

где x_i — значение оценки i -го респондента, n — объем выборки.

2. Система показателей вариации

При разделении совокупности на k групп (страт или кластеров) по определенному признаку, вариация признака анализируется через систему взаимосвязанных показателей:

- **Выборочная дисперсия** ($\hat{\sigma}^2$) — характеризует вариацию признака во всей совокупности под влиянием всех факторов:

$$\hat{\sigma}^2 = \frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n - 1}, \quad (3)$$

где

x_i — i -ое значение из выборки,

$\bar{x}$ — среднее по всей выборке,

n — размер выборки.

- **Внутригрупповая дисперсия** ($\hat{\sigma}_j^2$) — отражает случайную вариацию в каждой отдельной j -й группе, вызванную факторами, не принятыми за основание группировки:

$$\hat{\sigma}_j^2 = \frac{\sum_{i=1}^{n_j} (x_{ij} - \bar{x}_j)^2}{n_j - 1}, j = \overline{1, k} \quad (4)$$

где

x_{ij} — i -ое значение из j -ой группы;

$\bar{x}_j$ — среднее по всей j -ой группе;

n_j — размер j -ой группы.

- **Средняя из внутригрупповых дисперсий** ($\overline{\hat{\sigma}^2}$) — характеризует вариацию, обусловленную всеми факторами, за исключением фактора группировки:

$$\overline{\hat{\sigma}^2} = \frac{\sum_{j=1}^k \hat{\sigma}_j^2 \cdot n_j}{\sum_{j=1}^k n_j}, \quad (5)$$

где

s_j — внутригрупповая дисперсия,

n_j — размер j -ой группы.

- **Межгрупповая дисперсия** (δ^2) — характеризует вариацию результативного признака, обусловленную исключительно влиянием фактора, положенного в основу группировки:

$$\delta^2 = \frac{\sum_{j=1}^k (\bar{x}_j - \bar{x})^2 \cdot n_j}{\sum_{j=1}^k n_j}, \quad (6)$$

где

$\bar{x}_j$ — среднее j -ой группы,

$\bar{x}$ — среднее по всем группам,

n_j — размер j -ой группы.

Согласно *правилу сложения дисперсий*, общая дисперсия равна:

$$\hat{\sigma}^2 = \overline{\hat{\sigma}^2} + \delta^2. \quad (7)$$

3. **Предельная ошибка выборки** — максимально возможное отклонение выборочной средней от генеральной для заданной доверительной вероятности. Рассчитывается по формуле:

$$\Delta = t \cdot \sqrt{\frac{\hat{\sigma}_{sample}^2}{n}} \cdot \eta, \quad (8)$$

где

$\hat{\sigma}_{sample}^2$ — выборочная дисперсия метода,

t — квантиль распределения, определяемый уровнем значимости α^2 ,

η — поправка на конечный объем совокупности (9),

n — объемы выборки,

N — объем генеральной совокупности.

$$\eta = \begin{cases} \sqrt{1 - \frac{n}{N}} & (\text{для бесповторного отбора}), \\ 1, & (\text{для повторного отбора}). \end{cases} \quad (9)$$

1.4. Оценка и обоснование объема выборки

Для подтверждения *репрезентативности* данных в работе проводится расчет *минимально необходимого объема выборки* (n_{min}) с использованием итерационной схемы, согласно требованиям технического задания.

Итерационный алгоритм расчета

Процесс вычисления n_{min} разделен на три этапа, что позволяет учесть форму распределения при малых выборках и конечность генеральной совокупности:

1. **Расчет первого приближения** (n_0^*). Используется квантиль стандартизованного нормального распределения z для заданного уровня значимости α^2 :

$$n_0^* = \frac{z^2 \cdot \hat{\sigma}_{sample}^2}{\Delta_{GP}^2}, \quad (10)$$

²В работе уровень значимости принимается равным $\alpha = 0,05$, что соответствует доверительной вероятности $P = 0,95$

где

$\hat{\sigma}_{sample}^2$ — соответствующий методу вид дисперсии,

Δ_{GP} — соответствующая методу предельная ошибка генеральной совокупности³

.

2. **Уточнение через распределение Стьюдента (n_1^*).** На основе полученного n_0^* определяется число степеней свободы, и вычисляется уточненный коэффициент доверия t_{new} с помощью распределения Стьюдента:

$$n_1^* = \frac{t_{new}^2 \cdot \hat{\sigma}_{sample}^2}{\Delta_{GP}^2} \quad (11)$$

3. **Финальная корректировка (n^*).** Для методов, предполагающих бесповторный отбор, производится пересчет с учетом объема генеральной совокупности N :

$$n^* = \begin{cases} n_1^* & (\text{для повторного способа}), \\ \frac{N \cdot n_1^*}{N + n_1^*} & (\text{для бесповторного способа}). \end{cases} \quad (12)$$

Итоговый минимальный объем выборки принимается как $n_{min} = \lceil n^* \rceil$.

1.5. Методика проверки статистической несмещенности на основе Z-критерия

Для оценки качества работы алгоритмов формирования выборки в рамках имитационного моделирования был применен *статистический тест* для результатов. Ключевым критерием точности метода в данной работе выступает свойство несмещенности оценки математического ожидания.

Поскольку параметры исходной базы данных⁴ известны полностью, для проверки гипотезы о равенстве выборочного среднего ($\bar{x}$) и истинного сред-

³Согласно техническому заданию, оценка производится по уполовиненной величине предельной ошибки соответствующего метода: $\Delta_{GP} = \frac{\Delta}{2}$

⁴Принимается за генеральную совокупность в работе.

него (μ) используется двухсторонний Z -тест. Применение данного критерия обосновано следующими факторами:

1. Известна **дисперсия генеральной совокупности** (σ^2).
2. Ввиду *центральной предельной теоремы* распределение средних значений, полученных в ходе достаточного большого числа итераций, стремится к **нормальному распределению** $\mathcal{N}(\mu, \frac{\sigma^2}{n})$ независимо от закона распределения исходных данных в мастер-таблице.

Математическая модель проверки строится на тестировании системы гипотез:

$$\begin{cases} H_0 : \bar{x} = \mu & (\text{нулевая гипотеза}), \\ H_1 : \bar{x} \neq \mu & (\text{альтернативная гипотеза}). \end{cases} \quad (13)$$

Для каждого метода и исследуемого признака рассчитывается эмпирическое значение Z -статистики:

$$Z_{emp} = \frac{\bar{x} - \mu}{SE_{sim}} \quad (14)$$

Стандартная ошибка SE_{sim} в контексте имитационного моделирования рассчитывается по формуле:

$$SE_{sim} = \sqrt{\frac{\hat{\sigma}^2}{n \cdot k}} \cdot \eta \quad (15)$$

где

$\hat{\sigma}^2$ — несмещенная оценка дисперсии метода,

n — объем единичной выборки,

k — количество итераций моделирования,

η — поправочный коэффициент, зависящий от типа отбора (9).

Нулевая гипотеза отвергается, если расчетное значение p -value оказывается меньше α^2 :

$$p\text{-value} = 2 \cdot (1 - \Phi(|Z_{emp}|)) \quad (16)$$

где Φ — функция Лапласа.

$$\Phi(x) = \frac{1}{\sqrt{2\pi}} \int_0^x e^{-\frac{t^2}{2}} dt. \quad (17)$$

В случае отклонения гипотезы H_0 метод признается смещенным для данной конфигурации параметров.

2. Реализация

В данном разделе описывается программная реализация исследования на языке *Python*. Весь код структурирован в виде Jupyter Notebook и разбит на логические блоки: предобработка данных, реализация методов отбора, оценка параметров выборки и симуляция.

2.1. Используемые библиотеки

Для реализации алгоритмов использовались следующие библиотеки:

- `numpy` — векторизованные вычисления и генерация псевдослучайных чисел;
- `pandas` — загрузка, хранение и агрегация табличных данных;
- `scipy.stats` — квантили распределений Стьюдента и нормального;
- `matplotlib` и `seaborn` — визуализация результатов;
- `functools.partial` — частичное применение функций для единообразного вызова методов отбора.

2.2. Загрузка и предобработка данных

Исходные данные загружаются из файла Excel и сортируются по коду респондента. Для каждого респондента формируется метка страты как конкатенация его возрастной группы и пола:

```
1 df["Stratum"] = df["Возрастная группа"] + "_" + df["Пол"]
```

Столбцы мастер-таблицы разбиваются на блоки: метаданные, оценки *идеального* продукта, веса *важности* параметров и оценки каждого из трех брендов (Sony, JBL, Marshall).

```
1 data_cols = data.columns[METADATA_COLS:]
2 chunks = np.split(data_cols, SECTIONS_COUNT)
3 ideal_cols, imp_cols, *brand_col_groups = chunks
```

2.3. Вычисление интегральных показателей по модели идеальной точки

Для каждого респондента и каждого бренда вычисляется интегральный балл отклонения от идеала по формуле 1 из раздела методологии.

Реализация использует векторизованные операции NumPy:

```
1 for name in BRAND_NAMES:
2     brand_cols = brands[name]
3     score = (np.abs(ideal_col - df[brand_cols]) * imp_col).sum(axis=1)
4     all_scores.append(score)
5
6 pop_scores = np.column_stack(all_scores)
```

Результатом является матрица `scores` размером $N \times 3$, где каждая строка соответствует респонденту, а столбцы — трем брендам. На ее основе вычисляются *истинные* (генеральные) средние значения и определяется бренд, наиболее близкий к идеалу.

Результаты по генеральной совокупности:

Бренд	Среднее отклонение от идеальной точки
Sony	76,2565
JBL	76,3946
Marshall	76,9517

Таблица 1. Генеральные средние по модели идеальной точки

Бренд, наиболее близкий к идеалу — **Sony**.

2.4. Реализация методов отбора

Для уменьшения времени выполнения кода в дальнейшем было решено реализовать функции отбора таким образом, чтобы они возвращали индексы строк из таблицы, а не сами строки.

Несмотря на то что *механический* отбор подразумевает только неповторный характер, для унификации все функции отбора обладают тремя обязательными общими параметрами: `n` — желаемым объемом выборки,

replace — характером отбора (повторный или бесповторный) и seed — зерном для воспроизводимости результатов (в случае *механического* отбора этот параметр назван start_iter — начальная точка отсчета).

Случайный отбор

Выборка формируется с помощью генератора псевдослучайных чисел numpy.random.default_rng путем случайного выбора n индексов из генеральной совокупности (с повторением или без):

```
1 def sample_random(n_total: int, n: int, replace: bool, seed: int) ->
  ↪ np.ndarray:
2     indices_random = np.random.default_rng(seed).choice(n_total,
  ↪ size=n, replace=replace)
3     return indices_random
```

Механический отбор

Элементы отбираются через равный шаг $k = \lfloor N/n \rfloor$, начиная с фиксированной стартовой позиции в середине массива. Данный метод поддерживает только бесповторный способ (несмотря на параметр replace — он ни на что не влияет):

```
1 def sample_mechanical(n_total: int, n: int, replace: bool = False,
  ↪ start_iter: int = 0) -> np.ndarray:
2     k = N_TOTAL // n
3     start = N_TOTAL // 2 + start_iter
4     indices_mech = (start + np.arange(n) * k) % n_total
5     return indices_mech
```

Типический (стратифицированный) отбор

Генеральная совокупность предварительно разбита на страты по поло-возрастному признаку. Из каждой страты случайным образом отбирается количество элементов, пропорциональное ее доле в совокупности:

```

1 def sample_typical(stratum_weights: dict, n: int, replace: bool, seed:
  ↪ int, get_strats: bool = False):
2     rng = np.random.default_rng(seed)
3     parts = []
4
5     for s, w in stratum_weights.items():
6         pool = strata_groups[s]
7         n_s = max(1, round(n * w))
8         n_s = n_s if replace else min(n_s, len(pool))
9         parts.append(rng.choice(pool, size=n_s, replace=replace))
10
11     indices_typ = np.concatenate(parts)
12
13     if not get_strats:
14         return indices_typ
15
16     return indices_typ, parts

```

Кластерный отбор

Единицей отбора выступает кластер (станция). Количество отбираемых кластеров вычисляется исходя из средней наполненности кластера. Затем случайным образом выбираются r кластеров, и все входящие в них респонденты включаются в выборку:

```

1 def sample_cluster(cluster_keys: list, n: int, replace: bool, seed:
  ↪ int, get_clusters: bool = False):
2     rng = np.random.default_rng(seed)
3     r = round(n / AVG_PEOPLE_PER_CLUSTER)
4     r = r if replace else min(r, len(cluster_keys))
5
6     chosen_clusters = rng.choice(cluster_keys, size=r, replace=replace)
7     selected = [cluster_groups[c] for c in chosen_clusters]
8     indices_cluster = np.concatenate(selected)
9
10    if not get_clusters:
11        return indices_cluster
12
13    return indices_cluster, selected

```

2.5. Оценка дисперсий разведочной выборки

На основе разведочной выборки объема⁵ оцениваются дисперсии, соответствующие каждому методу отбора):

- **Случайный и механический** — общая выборочная дисперсия (3),
- **Типический** — средняя из внутригрупповых дисперсий страт (5),
- **Кластерный** — межгрупповая дисперсия средних по кластерам (6).

```
1 leader_scores = pop_scores[:, best_brand]
2
3 # Случайный
4 idx_rnd = methods["Случайный"](N_SAMPLE, True, SEED)
5 var_rnd = leader_scores[idx_rnd].var(ddof=1)
6
7 # Механический
8 idx_mech = methods["Механический"](N_SAMPLE, False, SEED)
9 var_mech = leader_scores[idx_mech].var(ddof=1)
10
11 # Типический
12 idx_typ, parts = methods["Типический"](N_SAMPLE, True, SEED,
13   ↪ get_strats=True)
14 sizes = np.array([len(p) for p in parts])
15 variances = np.array([leader_scores[p].var(ddof=1) for p in parts])
16 var_typ = np.average(variances, weights=sizes)
17
18 # Кластерный
19 idx_clst, selected = methods["Кластерный"](N_SAMPLE, True, SEED,
20   ↪ get_clusters=True)
21 cluster_means = np.array([leader_scores[p].mean() for p in selected])
22 var_clst = np.var(cluster_means)
```

⁵Согласно техническому заданию объем разведочной совокупности принимается равным 4% от генеральной совокупности.

3. Результаты исследования

В данном разделе представлены результаты анализа репрезентативности методов формирования выборки, полученные в ходе имитационного моделирования.

3.1. Результаты разведочного анализа

На первом этапе были рассчитаны дисперсии разведочных выборок и оценена устойчивость выводов о лидирующем бренде. Эти показатели легли в основу дальнейшего расчета необходимого объема целевой совокупности.

Оценки дисперсий по методам отбора:

Метод отбора	Требуемая дисперсия
Кластерный	8,7509
Типический	509,8195
Механический	837,0244
Случайный	861,5636

Таблица 2. Дисперсии разведочных выборок по методам

Наименьшая дисперсия у *кластерного метода* объясняется высокой внутрикластерной однородностью: опрашиваемые на одной станции демонстрируют схожие предпочтения, поэтому межгрупповая вариация оказывается очень мала. *Типический метод* демонстрирует выигрыш в точности по сравнению со случайным за счет исключения межгрупповой составляющей вариации, поскольку стратификация по поло-возрастному признаку выделяет однородные подгруппы.

3.2. Анализ устойчивости на малых выборках

Для оценки надежности выводов на этапе разведки каждый метод запускался 100 раз с различными зернами генератора. Подсчитывалось, сколько раз каждый из брендов имел минимальное среднее отклонение от идеала.

При малом объеме выборки бренды **Sony** и **JBL** статистически неразличимы — при разных зернах генератора победителем может стать как первый, так и второй. То есть победитель определяется случайным составом выборки,

Метод	Sony	JBL	Marshall
Случайный	42	42	16
Механический	52	32	16
Типический	40	38	22
Кластерный	46	41	13

Таблица 3. Частота победы каждого бренда за 100 итераций

а не способом ее формирования. Это подтверждает необходимость перехода к расчету минимально необходимого объема выборки (n_{min}).

3.3. Минимальный объем выборки и точность

Используя итерационную схему, были определены объемы выборок, обеспечивающие заданную предельную ошибку³...

Метод отбора	Предельная ошибка выборки	Целевая предельная ошибка
Случайный	2,3534	1,1767
Механический	2,2728	1,1364
Типический	1,8103	0,9052
Кластерный	1,9873	0,9937

Таблица 4. Сравнительные показатели точности методов отбора

На основе этих данных сформированы требования к объему итоговых выборок для имитационной модели:

Поскольку целевая ошибка Δ_{GP}^3 была задана относительно текущей ошибки метода, дисперсия метода математически сокращается (следует из формул (8), (10) и (11)) при расчете первого и второго приближений минимального объема выборки. На заданном зерне⁶ объемы изначальных выборок для *типического* и *случайного* методов совпали, чего могло и не произойти. Поэтому мы наблюдаем одинаковые новые минимальные объемы выборок для этих двух методов.

⁶SEED = 100

Метод	Повт.	Мин. объем (n_{min})
Случайный	Да	2393
	Нет	2064
Механический	Нет	2138
Типический	Да	2393
	Нет	2064
Кластерный	Да	1934
	Нет	1713

Таблица 5. Минимальный объем выборки по методам и способам отбора

3.4. Имитационное моделирование

Для каждой из семи комбинаций метода и способа отбора проводилось 10 000 симуляций. На каждой итерации формировалась выборка объема n_{min} , вычислялись средние оценки трех брендов и фиксировался победитель.

3.4.1 Устойчивость определения лидера

При достижении объема n_{min} неопределенность, характерная для разведочного анализа, исчезает.

Метод	Повт.	Объем (n_{min})	Лидер	Частота побед (%)
Кластерный	Нет	1713	Sony	56,86
	Да	1934	Sony	56,55
Механический	Нет	2138	Sony	51,83
Случайный	Нет	2064	Sony	57,27
	Да	2393	Sony	57,05
Типический	Нет	2064	Sony	58,40
	Да	2393	Sony	58,24

Таблица 6. Устойчивость выявления лидера за 10 000 итераций

Как видно из таблицы 6, во всех конфигурациях лидером является **Sony**. Наиболее высокий процент побед показывает типический метод (до 58,4%).

3.4.2 Усредненные оценки и вариативность

Метод	Повт.	Бренд	Среднее	СКО
Кластерный	Нет	Sony	76,2662	0,4445
		JBL	76,4096	0,3939
		Marshall	76,9619	0,3649
	Да	Sony	76,2605	0,4321
		JBL	76,4076	0,3818
		Marshall	76,9604	0,3454
Механический	Нет	Sony	76,2569	0,3322
		JBL	76,3946	0,2817
		Marshall	76,9521	0,1719
Случайный	Нет	Sony	76,2622	0,3644
		JBL	76,3954	0,3423
		Marshall	76,9507	0,2722
	Да	Sony	76,2594	0,3592
		JBL	76,3995	0,3406
		Marshall	76,9559	0,2711
Типический	Нет	Sony	76,2406	0,2101
		JBL	76,3803	0,2022
		Marshall	76,9430	0,2040
	Да	Sony	76,2566	0,2137
		JBL	76,3983	0,2048
		Marshall	76,9531	0,2039

Таблица 7. Статистические показатели брендов по методам формирования выборки

Все рассмотренные методы корректно воспроизводят иерархию брендов⁷ по показателю среднего отклонения. Это подтверждает, что качественный вывод

⁷ Sony < JBL < Marshall

о лидере рынка *сохраняет устойчивость вне зависимости от выбранного способа формирования выборки.*

3.4.3 Проверка статистической несмещенности

Для верификации точности был применен Z-тест. Согласно описанной ранее методике проверки статистической несмещенности, основной целью данного этапа является подтверждение нулевой гипотезы.

Метод	Повт.	Статистическая несмещенность (бренды)	Средняя дисперсия
Кластерный	Да	2/3	0,3864
	Нет	2/3	0,4011
Механический	Нет	3/3	0,2619
Случайный	Да	3/3	0,3236
	Нет	3/3	0,3263
Типический	Да	3/3	0,2075
	Нет	1/3	0,2055

Таблица 8. Результаты проверки точности и надежности методов формирования выборки

Несмотря на минимальную дисперсию (0,2055) у *повторного типического* метода отбора, он обеспечивает несмещенность лишь для одного из трех брендов. Это объясняется тем, что при большом n_{min} и фиксированном объеме страт бесповторный отбор фактически исчерпывает часть страт, нарушая случайность и внося систематическое отклонение. *Кластерный* метод демонстрирует аналогичную структурную проблему независимо от режима повторности — следствие внутрикластерной однородности по предпочтениям к отдельным брендам.

Оптимальным по совокупности критериев является **типический повторный** метод: он единственный достигает полной несмещенности (3/3) при наименьшей дисперсии среди несмещенных методов (0,2075).

3.5. Визуализация и интерпретация

Для итогового сравнения надежности методов построена столбчатая диаграмма дисперсии оценок по каждому бренду в разбивке по методу и способу отбора (рис. 1).




Рис. 1. Сравнение надежности методов: дисперсия оценок по брендам

Случайный метод служит базовым ориентиром для сравнения: не используя никакой информации о структуре совокупности, он демонстрирует наибольшую дисперсию среди несмещённых методов. Повторный и бесповторный режимы дают практически идентичные результаты — при $n \ll N$ поправка на бесповторность пренебрежимо мала. Повышенная дисперсия для Sony и JBL относительно Marshall свидетельствует о неоднородности предпочтений респондентов к этим брендам, которую случайный отбор не способен контролировать.

На диаграмме четко прослеживается превосходство **типичского отбора**: он обеспечивает минимальный разброс оценок для всех трех брендов,

что делает его наиболее предпочтительным для маркетинговых исследований в условиях известной структуры совокупности.

Кластерный метод уступает всем остальным по стабильности оценок: высокая дисперсия отражает сильную зависимость результата от того, какие именно кластеры попали в выборку.

Аномально низкая дисперсия **механического метода** для бренда Marshall, возможно, вызван равномерным распределением оценок этого бренда вдоль отсортированного датасета: при фиксированном шаге k любая стартовая позиция захватывает репрезентативное подмножество.

Заключение

В данной работе проведён сравнительный анализ четырёх методов статистического отбора — *случайного, механического, типического и кластерного* — применительно к задаче оценки потребительских предпочтений в отношении аудио-брендов Sony, JBL и Marshall по модели идеальной точки. По результатам исследования можно сформулировать следующие выводы.

Лидер рынка однозначно определен. По генеральной совокупности бренд Sony имеет наименьшее среднее отклонение от идеальной точки. Этот вывод устойчив: во всех семи конфигурациях имитационного моделирования и при 10 000 итераций именно Sony занимала первое место по пользовательским предпочтениям.

Объема разведочной выборки в 4% от генеральной совокупности недостаточно для разграничения лидеров. Sony и JBL статистически неразличимы — они делят победы примерно поровну по всем методам. Это подтверждает необходимость применения итерационной схемы расчёта минимально необходимого объёма выборки n_{min} , после достижения которого неопределённость устраняется.

Можно заключить, что для маркетинговых исследований в условиях известной поло-возрастной структуры аудитории рекомендуется применять типический повторный отбор: он контролирует состав выборки, исключает межгрупповую составляющую вариации и обеспечивает наиболее стабильные и несмещённые оценки интегрального показателя брендов.

Итогом работы стала реализация автоматизированного цикла обработки данных, интегрирующего методы математической статистики с алгоритмами бизнес-аналитики. Созданный программный комплекс позволяет не только рассчитывать рейтинги брендов, но и количественно оценивать надёжность полученных результатов, обеспечивая воспроизводимость исследований на произвольных структурах данных

Список литературы

1. Гмурман, В. Е. Теория вероятностей и математическая статистика: учебное пособие / В. Е. Гмурман. — 12-е изд. — Москва : Юрайт, 2014. — 479 с.
2. Чернова, Н. И. Математическая статистика : учебное пособие / Н. И. Чернова ; Новосибирский государственный университет. — Новосибирск : НГУ, 2007. — 148 с.
3. Документация библиотеки NumPy [Электронный ресурс]. — Режим доступа: <https://numpy.org/doc/> (дата обращения: 10.04.2026).
4. Документация библиотеки SciPy (модуль `scipy.stats`) [Электронный ресурс]. — Режим доступа: <https://docs.scipy.org/doc/scipy/reference/stats.html> (дата обращения: 10.04.2026).