

**Федеральное государственное автономное образовательное учреждение
высшего образования
«Национальный исследовательский ядерный университет «МИФИ»**

ОТЧЕТ

по лабораторной работе №2 (вариант 42)
по дисциплине: «Математическая статистика и машинное обучение»

Выполнил: *студент группы Б24-215*

Гаганидзе Г. Г.

(подпись)

(Фамилия И.О.)

Проверил:

Смирнов Д. С.

(оценка)

(подпись)

(Фамилия И.О.)

Москва 2026 г.

Содержание

Введение	2
1 Методология исследования	3
1.1 Общая схема модели	3
1.2 Учет сообществ	3
1.3 Линеаризация признаков	4
1.4 Критерий качества	4
2 Реализация	5
3 Результаты исследования	6
3.1 Отбор состояний, связанных со счастьем	6
3.2 Анализ сферы занятости и сообществ	7
3.3 Поиск нелинейных функций	7
3.4 Качество восстановления состояний	10
3.5 Сравнение моделей классификации счастья	11
3.6 Матрица ошибок	12
3.7 Прогноз для неизвестных наблюдений	13
Заключение	14
Список литературы	15

Введение

В данной лабораторной работе исследуется задача прогнозирования интегрального показателя субъективного благополучия — *ощущаемого счастья* респондента. Исходный массив содержит две группы признаков: признаки *состояния* (субъективные оценки) и признаки *причины* (индивидуальные и общественные характеристики). Для строк, где счастье неизвестно, необходимо построить прогноз.

Актуальность работы состоит в том, что прямое использование признаков состояния для прогноза недоступно для неизвестных наблюдений. Поэтому потребовалось построить двухэтапную модель: сначала восстановить состояния по причинам, а затем по восстановленным состояниям и доступным причинам предсказать категорию счастья.

Цель работы — разработать интерпретируемую модель, позволяющую получить значение *micro precision*, близкое к требуемому порогу 0,6, и одновременно объяснить, какие факторы ограничивают качество прогноза.

Для достижения цели были поставлены следующие **задачи**:

1. выявить состояния, наиболее связанные с ощущаемым счастьем;
2. построить модели МНК для восстановления выбранных состояний по причинам;
3. проанализировать сообщества и сферу занятости как категориальные факторы;
4. проверить нелинейные преобразования причин и оценить изменение R^2 ;
5. построить логистическую регрессию с регуляризацией и сравнить несколько конфигураций признаков;
6. сформировать прогноз для наблюдений с неизвестным счастьем.

1. Методология исследования

1.1. Общая схема модели

Основная методологическая сложность заключалась в том, что признаки состояния имеются только для наблюдений с известным счастьем. Поэтому прямой сценарий

реальные состояния $\rightarrow$ счастье

является слишком оптимистичным и не соответствует реальной задаче. В работе была использована следующая схема:

причины $\rightarrow$ предсказанные состояния $\rightarrow$ счастье.

На первом этапе для каждого выбранного состояния S_j строилась регрессионная модель:

$$S_j = \beta_0 + X_{cause}\beta + D_{sphere}\gamma + D_{community}\delta + \varepsilon, \quad (1)$$

где X_{cause} — индивидуальные и общественные причины, D_{sphere} — dummy-переменные сферы занятости, $D_{community}$ — фиксированные эффекты сообществ.

На втором этапе обучалась мультиномиальная логистическая регрессия:

$$P(y = k|z) = \frac{\exp(w_k^T z)}{\sum_m \exp(w_m^T z)}, \quad (2)$$

где z включает предсказанные состояния, причины и при необходимости категориальные факторы. Для борьбы с переобучением применялась L2-регуляризация.

1.2. Учет сообществ

Общественные признаки имеют количественную природу, однако внутри одного сообщества они постоянны. Поэтому их комбинация фактически задаёт категориальный признак `community_id`, разделяющий данные на 25 групп.

Это было важно по двум причинам. Во-первых, люди внутри одного сообщества не являются полностью независимыми наблюдениями. Во-вторых, средний уровень счастья по сообществам заметно различается, поэтому фиксированные эффекты сообщества могут существенно улучшать прогноз.

В финальной версии использовался построчный сценарий валидации. Это означает, что модель оценивает качество прогноза для новых респондентов из уже представленных типов сообществ. Более строгая проверка по новым сообществам также рассматривалась ранее, но она сильнее снижает качество и отвечает на другой прикладной вопрос.

1.3. Линеаризация признаков

Для повышения качества моделей МНК был реализован автоматический поиск нелинейных функций. Для подозреваемых причин проверялись преобразования:

`log1p(x)`, `sqrt(x)`, `cbrt(x)`, `log_shift(x)`, `sqrt_shift(x)`,
`inv_shift(x)`, z^2 , z^3 , z^4 , $|z|$ и hinge-функции.

Для каждого состояния сравнивались базовое значение $OOF R^2$ и значение после добавления отдельной функции. Преобразование оставлялось только при достаточном приросте R^2 , чтобы не усложнять модель без практической пользы.

1.4. Критерий качества

В качестве основной метрики использовалась *micro precision*. В задаче однометочной многоклассовой классификации она совпадает с *accuracy*:

$$Precision_{micro} = \frac{\sum_k TP_k}{\sum_k (TP_k + FP_k)} = Accuracy. \quad (3)$$

2. Реализация

Программная реализация выполнена в Jupyter Notebook на языке *Python*. Код был переписан в структурированном виде: вместо «макаронного» скрипта были выделены функции для формирования признаков, построения *dummy*-переменных, поиска нелинейностей, обучения МНК и обучения классификатора.

Для удобства экспериментов были введены флаги:

```
USE_SPHERE_IN_STATE_MODELS = True
USE_COMMUNITY_IN_STATE_MODELS = True
USE_LINEARIZATION_IN_STATE_MODELS = True

USE_PREDICTED_STATES_IN_CLASSIFIER = True
ADD_CAUSES_TO_CLASSIFIER = True
USE_SPHERE_IN_CLASSIFIER = True
USE_COMMUNITY_IN_CLASSIFIER = True
```

Это позволило быстро сравнить несколько вариантов модели: только предсказанные состояния, предсказанные состояния вместе с причинами, а также расширение за счет сферы занятости и сообщества.

Исходная таблица содержит 1900 наблюдений с известным счастьем и 600 строк, для которых целевой признак неизвестен. Было найдено 25 сообществ. Распределение классов счастья заметно несбалансировано: класс *Prospering* встречается редко, что дополнительно усложняет классификацию.




Рис. 1. Распределение классов счастья в обучающей части

3. Результаты исследования

3.1. Отбор состояний, связанных со счастьем

На первом этапе для каждого состояния рассчитывалась ранговая корреляция Спирмена с числовым рангом счастья. В таблице представлены шесть наиболее связанных состояний.

Состояние	Spearman	p-value
Оценка социальной поддержки	0,76	0,00
Чувство технологического прогресса	0,71	0,00
Индекс кредитного оптимизма	0,69	0,00
Индекс продовольственной безопасности	0,59	0,00
Индекс семьи	0,54	0,00
Чувство неравенства доходов в обществе	-0,37	0,00

Таблица 1. Состояния, наиболее связанные с ощущаемым счастьем

Сильнее всего со счастьем связаны оценка социальной поддержки, чувство технологического прогресса и индекс кредитного оптимизма. Эти при-

знаки стали ключевыми кандидатами для последующего восстановления по причинам.

3.2. Анализ сферы занятости и сообществ

Связь сферы занятости с счастьем проверялась с помощью таблицы сопряженности. Критерий χ^2 показал наличие статистической связи: $\chi^2 = 69,25$, $p = 0,01$. Однако в финальном классификаторе сфера занятости не стала главным фактором улучшения: лучший вариант модели оказался без её добавления.

Сообщества оказались существенно более важным фактором. Средний rank счастья в разных сообществах менялся примерно от 0,3 до 7,2. Это означает, что принадлежность к сообществу несет сильный сигнал о типичном уровне счастья.



Рис. 2. Различия среднего уровня счастья между сообществами

3.3. Поиск нелинейных функций

Для состояний были проверены нелинейные функции причин. На рисунке показан пример диагностики: исходная зависимость, LOWESS-сглаживание, остатки линейной модели и зависимость после преобразования.




Рис. 3. Пример анализа нелинейности с LOWESS-сглаживанием

Лучшие одиночные преобразования представлены в таблице 2. В ней показаны не только сами функции, но и качество модели до и после их добавления. Для удобства значения R^2 округлены до двух знаков, а прирост показан в процентных пунктах. Видно, что даже лучшие функции давали очень маленький дополнительный выигрыш: максимум около 0,35 п.п. Поэтому в итоговую модель линеаризующие функции не вошли: после учета сообщества их практическая польза оказалась недостаточной.

Состояние	Причина	Функция	Баз. R^2	Нов. R^2	ΔR^2
Индекс кредитного оптимизма	Количество лет образования	log_shift	0,9173	0,9208	0,0035
Индекс кредитного оптимизма	Количество лет образования	sqrt_shift	0,9173	0,9207	0,0034
Индекс кредитного оптимизма	Количество лет образования	inv_shift	0,9173	0,9207	0,0034
Индекс кредитного оптимизма	Количество лет образования	z4	0,9173	0,9204	0,0031
Индекс кредитного оптимизма	Количество лет образования	log1p	0,9173	0,9204	0,0031
Индекс кредитного оптимизма	Количество лет образования	cbirt	0,9173	0,9204	0,0031
Индекс кредитного оптимизма	Количество лет образования	sqrt	0,9173	0,9203	0,0030
Индекс кредитного оптимизма	Количество лет образования	z2	0,9173	0,9198	0,0025
Индекс кредитного оптимизма	Количество лет образования	low_q25	0,9173	0,9197	0,0024
Индекс кредитного оптимизма	Количество лет образования	hinge_q25	0,9173	0,9197	0,0024
Индекс кредитного оптимизма	Количество лет образования	hinge_q50	0,9173	0,9195	0,0022
Индекс семьи	Среднегодовой доход, тыс. \$	z2	0,4727	0,4742	0,0015

Таблица 2. Лучшие проверенные нелинейные преобразования и изменение $OOF R^2$

Несмотря на то, что некоторые нелинейные преобразования давали положительный прирост, его величина оказалась небольшой: максимальное улучшение составило только $\Delta R^2 = 0,0035$. Поэтому в итоговую модель дополнительные функции линеаризации не включались: основной вклад в качество восстановления состояний дал учет фиксированных эффектов сообществ.




Рис. 4. Прирост $OOF R^2$ для лучших нелинейных преобразований

3.4. Качество восстановления состояний

После учета причин, сообщества и сферы занятости были построены МНК-модели для предсказания выбранных состояний. Наиболее хорошо восстанавливались оценка социальной поддержки, индекс продовольственной безопасности, индекс кредитного оптимизма и чувство технологического прогресса.

Состояние	$OOF R^2$
Оценка социальной поддержки	0,93
Индекс продовольственной безопасности	0,93
Индекс кредитного оптимизма	0,92
Чувство технологического прогресса	0,90
Индекс семьи	0,47
Чувство неравенства доходов в обществе	0,14

Таблица 3. Качество восстановления состояний после учета причин и сообществ



Рис. 5. OOF R^2 моделей восстановления состояний

Высокие значения R^2 для части состояний объясняются прежде всего добавлением `community_id`. Модель стала учитывать устойчивые различия между сообществами, а не только индивидуальные причины. Это особенно важно для оценки социальной поддержки, продовольственной безопасности, кредитного оптимизма и чувства технологического прогресса: данные состояния заметно отличаются по среднему уровню между сообществами. Линеаризация в финальной версии фактически не понадобилась: проверенные функции почти не увеличивали R^2 сверх эффекта сообщества, поэтому были исключены жадным отбором.

3.5. Сравнение моделей классификации счастья

На финальном этапе сравнивались несколько конфигураций логистической регрессии. Лучший результат дала модель, использующая предсказанные состояния, причины и фиксированные эффекты сообщества.

Конфигурация	C	Micro precision
predicted_states + causes + community	3,00	0,59
predicted_states + causes + sphere + community	10,00	0,58
predicted_states + causes	0,30	0,58
predicted_states + causes + community	10,00	0,58
predicted_states + causes + sphere + community	3,00	0,58

Таблица 4. Лучшие конфигурации логистической регрессии

Итоговая лучшая модель:

predicted states + causes + community, $C=3$, class_weight=None.

Таким образом, главный прирост качества был связан не с усложнением формы функций, а с правильным использованием структуры данных. Предсказанные состояния дают содержательную интерпретацию, причины добавляют прямой сигнал, а community_id учитывает устойчивые различия между группами. Сфера занятости статистически связана с целевой переменной, но в итоговом прогнозе оказалась менее полезной, чем фактор сообщества.

3.6. Матрица ошибок

На рисунке представлена матрица ошибок лучшей модели. Видно, что модель лучше распознает крайние или более устойчивые классы, например *Hopeless*, *Doing well*, *Blooming*, *Thriving*. Основные ошибки возникают между соседними и близкими по смыслу категориями: *Suffering*, *Struggling*, *Coping*, *Just ok*. Это естественно для упорядоченной шкалы счастья.




Рис. 6. Матрица ошибок лучшей модели

3.7. Прогноз для неизвестных наблюдений

После выбора финальной конфигурации модель была обучена на всех наблюдениях с известным счастьем и применена к 600 строкам, где целевой признак был равен Неизвестно. Распределение прогнозов представлено в таблице.

Предсказанный класс	Количество
Suffering	102
Doing well	99
Hopeless	73
Coping	70
Just ok	64
Depressed	58
Struggling	57
Blooming	44
Thriving	30
Prospering	3

Таблица 5. Распределение прогнозов для unknown-наблюдений



Рис. 7. Распределение предсказанных классов для unknown

Заключение

В ходе работы была построена двухэтапная модель прогнозирования ощущения счастья. Главная методологическая проблема заключалась в том, что реальные признаки состояния недоступны для неизвестных наблюдений. Поэтому была использована схема причины → предсказанные состояния →

счастье, а не искусственно завышающий качество сценарий реальные состояния
→ счастье.

Ключевым фактором улучшения результата стал учет `community_id`. Хотя общественные признаки являются количественными, их комбинация фактически задает категориальный фактор сообщества. Добавление фиксированных эффектов сообщества существенно повысило качество восстановления состояний и приблизило итоговую `micro precision` к требуемому порогу.

Сфера занятости была проверена как категориальный фактор и статистически связана с целевым признаком, однако в лучшей финальной модели она не дала основного прироста. Линеаризация также была подробно проверена: перебирались логарифмические, корневые, степенные, обратные и пороговые функции. В финальной версии она не понадобилась, поскольку после учета сообществ дополнительный прирост R^2 от нелинейных функций оказался практически незначимым.

Итоговая модель с конфигурацией

`predicted states + causes + community`

достигла значения **micro precision** = 0,59. Полученный результат близок к требуемому значению 0,6 и является приемлемым с учетом сложности задачи, несбалансированности классов и близости соседних категорий счастья.

Список литературы

1. Гмурман, В. Е. Теория вероятностей и математическая статистика: учебное пособие. — Москва : Юрайт, 2014.
2. Документация библиотеки `scikit-learn` [Электронный ресурс]. — Режим доступа: <https://scikit-learn.org/>.
3. Документация библиотеки `statsmodels` [Электронный ресурс]. — Режим доступа: <https://www.statsmodels.org/>.
4. Документация библиотек `NumPy`, `pandas`, `SciPy` [Электронный ресурс].