

**Федеральное государственное автономное образовательное учреждение
высшего образования
«Национальный исследовательский ядерный университет «МИФИ»**

ОТЧЕТ

по лабораторной работе №2 (вариант 42)
по дисциплине: «Математическая статистика и машинное обучение»

Выполнил: *студент группы Б24-215*

Гаганидзе Г. Г.

(подпись)

(Фамилия И.О.)

Проверил:

Смирнов Д. С.

(оценка)

(подпись)

(Фамилия И.О.)

Москва 2026 г.

Содержание

Введение	2
1 Методология исследования	3
1.1 Подготовка признаков	3
1.2 Отбор состояний	3
1.3 Восстановление состояний	3
1.4 Проверка нелинейностей	4
1.5 Сообщества	4
1.6 Классификатор и метрика	4
2 Реализация	6
3 Результаты исследования	8
3.1 VIF-фильтр и отбор состояний	8
3.2 Качество восстановления состояний	9
3.3 Нелинейности и сообщества	10
3.4 Качество классификации	15
3.5 Прогноз для unknown-наблюдений	17
Заключение	19
Список литературы	19

Введение

В лабораторной работе решалась задача прогнозирования интегрального показателя субъективного благополучия респондента — *ощущаемого счастья*. Данные содержат две группы признаков: причины, доступные для всех строк, и состояния, которые заполнены только для наблюдений с известным классом счастья. Для 600 наблюдений целевой признак равен Неизвестно, а признаки состояния в этих строках полностью отсутствуют.

Из-за этого прямое обучение классификатора на реальных состояниях некорректно: на known-части оно дает завышенную оценку качества, но не может быть применено к unknown-строкам. Поэтому основной подход в работе был двухэтапным:

причины → восстановленные состояния → счастье.

Цель работы — построить воспроизводимую модель для прогноза счастья, достигающую требуемого уровня micro precision не ниже 0,6, и объяснить, какие признаки и ограничения данных определяют качество прогноза.

Для достижения цели были поставлены следующие **задачи**:

1. удалить мультиколлинеарные причины с помощью VIF-фильтра;
2. отобрать состояния, наиболее связанные с рангом счастья;
3. восстановить выбранные состояния по причинам и сфере занятости;
4. проверить нелинейные преобразования причин и их влияние на R^2 ;
5. изучить роль сообществ как источника групповой структуры данных;
6. обучить логистическую регрессию и получить прогноз для unknown-строк.

1. Методология исследования

1.1. Подготовка признаков

Целевая переменная была упорядочена от класса *Hopeless* до класса *Prospering*. Каждому классу сопоставлялся числовой ранг от 0 до 9. Это позволило использовать ранговые корреляции при отборе состояний, но итоговая задача оставалась многоклассовой классификацией.

Причины предварительно проверялись на мультиколлинеарность. Использовался итеративный VIF-фильтр: пока максимальный VIF был не меньше 8, удалялся признак с наибольшим VIF. В результате были исключены два общественных признака: *издержки сообщества на окружающую среду* и *волатильность потребительских цен в сообществе*. Осталось 8 причин.

1.2. Отбор состояний

Для каждого состояния рассчитывалась корреляция Спирмена с рангом счастья. Кандидатами считались состояния с достаточно сильной монотонной связью:

$$|\rho_S(S_j, \text{rank}(y))| \geq 0,40. \quad (1)$$

После этого состояние оставлялось только если его удавалось восстановить по доступным признакам с качеством не ниже $R^2 = 0,70$. По итогам этого отбора в финальную схему вошли четыре состояния: социальная поддержка, технологический прогресс, кредитный оптимизм и продовольственная безопасность.

1.3. Восстановление состояний

Для восстановления состояний использовалась регуляризованная линейная модель Ridge:

$$\hat{S}_j = \beta_0 + X_{\text{cause}}\beta + D_{\text{sphere}}\gamma, \quad (2)$$

где X_{cause} — причины после VIF-фильтра, а D_{sphere} — dummy-признаки сферы занятости. Регуляризация уменьшает чувствительность коэффициентов к остаточной коррелированности признаков и к шуму в отдельных группах.

Качество восстановления оценивалось по out-of-fold-прогнозам. Это важно: классификатор на втором этапе обучался не на состояниях, полученных моделью, видевшей ту же строку при обучении, а на OOF-предсказаниях состояний.

1.4. Проверка нелинейностей

Для причин проверялся банк преобразований:

`z, z2, z3, z4, log1p, sqrt, cbrt, log_shift, sqrt_shift,
inv_shift`

и пороговые hinge-функции по квантилям. Преобразования сравнивались с базовой линейной моделью по изменению R^2 . В итоговой схеме отобранные преобразования использовались при восстановлении состояний. При этом отдельные одиночные преобразования давали небольшой прирост, а основной практический эффект банка проявился для наиболее сложного состояния — индекса кредитного оптимизма.

1.5. Сообщества

Общественные причины внутри одного сообщества постоянны. Их комбинация задает категориальный идентификатор `community_id`, который полезен для анализа групповой структуры данных. В ноутбуке проверялись варианты с включением `community_id` как `fixed effect`, однако на текущем `rowwise`-разбиении лучший воспроизводимый результат дала модель со сферой занятости, но без `community one-hot`. Поэтому сообщества использовались в отчете прежде всего для интерпретации и диагностики, а не как часть финального классификатора.

1.6. Классификатор и метрика

На втором этапе обучалась мультиномиальная логистическая регрессия:

$$P(y = k|z) = \frac{\exp(w_k^T z)}{\sum_m \exp(w_m^T z)}, \quad (3)$$

где z включает OOF-предсказания выбранных состояний, причины после VIF-фильтра и сферу занятости. Для регуляризации использовалась L2-норма, параметр логистической регрессии в финальном запуске равен $C = 8,0$.

Основная метрика — *micro precision*. В однометочной многоклассовой задаче она совпадает с *accuracy*:

$$Precision_{micro} = \frac{\sum_k TP_k}{\sum_k (TP_k + FP_k)}. \quad (4)$$

2. Реализация

Программная реализация выполнена в Jupyter Notebook `lab02.ipynb` на языке *Python*. Для воспроизводимости был зафиксирован `SEED = 7`. В ноутбуке отдельно реализованы функции для VIF-фильтрации, построения dummy-переменных, генерации банка нелинейных функций, восстановления состояний и обучения классификатора.

Основные параметры финального запуска:

```
SEED = 7
VIF_MAX = 8.0
SPEARMAN_MIN = 0.40
R2_MIN = 0.70
REG_ALPHA = 1.0
LOGREG_C = 8.0

USE_SPHERE_IN_STATE_MODELS = True
USE_COMMUNITY_IN_STATE_MODELS = False
USE_SPHERE_IN_CLASSIFIER = True
USE_COMMUNITY_IN_CLASSIFIER = False
```

В `known`-части содержится 1900 наблюдений, в `unknown`-части — 600 наблюдений. Состояния для `unknown`-строк отсутствуют полностью, поэтому они восстанавливались отдельной регрессионной моделью, обученной на `known`-части.




Рис. 1. Распределение классов счастья в known-части

Распределение классов несбалансировано. Особенно редко встречается класс *Prospering*: в known-части всего 9 таких наблюдений. Это ограничивает устойчивость оценок для верхнего края шкалы и частично объясняет ошибки между соседними категориями.

3. Результаты исследования

3.1. VIF-фильтр и отбор состояний

После VIF-фильтрации остались следующие причины: среднегодовой доход, объем потребленного алкоголя, количество членов семьи, количество лет образования, доля дохода на продовольствие, коэффициент Джини сообщества, охват беспроводной связи и число смертей от вирусных и респираторных заболеваний. Максимальный VIF после фильтрации не превышал 5,01.

Состояние	Spearman	p-value
Оценка социальной поддержки	0,7661	0,0000
Чувство технологического прогресса	0,7213	0,0000
Индекс кредитного оптимизма	0,7035	0,0000
Индекс продовольственной безопасности	0,6014	0,0000
Индекс семьи	0,5530	0,0000
Чувство неравенства доходов в обществе	-0,3788	0,0000

Таблица 1. Состояния с наибольшей связью с рангом счастья




Рис. 2. Ранговые корреляции состояний с рангом счастья

Первые четыре состояния не только сильно связаны со счастьем, но и достаточно хорошо восстанавливаются по причинам. *Индекс семьи* име-

ет заметную корреляцию с целевой переменной, но не проходит порог качества восстановления после выбранной схемы проверки, поэтому в финальный классификатор не включался.

3.2. Качество восстановления состояний

Состояние	Линейный R^2_{train}	После банка функций	ΔR^2
Оценка социальной поддержки	0,9193	0,9301	0,0108
Индекс продовольственной безопасности	0,9172	0,9276	0,0104
Чувство технологического прогресса	0,8924	0,9183	0,0259
Индекс кредитного оптимизма	0,7929	0,9161	0,1232

Таблица 2. Качество восстановления финально выбранных состояний




Рис. 3. Распределения причин после VIF-фильтра и выбранных состояний

Среднее OOF R^2 восстановления четырех состояний в проверочном запуске составило 0,9148. Самым сложным состоянием был индекс кредитного

оптимизма: для него линейная модель без банка функций давала заметно более низкое качество, а линеаризованные признаки позволили пройти порог отбора.

3.3. Нелинейности и сообщества

Наиболее заметная диагностированная нелинейность возникла для связи количества лет образования с индексом кредитного оптимизма. LOWESS-кривая показывает монотонный рост с насыщением на больших значениях образования, поэтому логарифмические и корневые преобразования выглядят содержательно оправданными.




Рис. 4. Диагностика нелинейности: индекс кредитного оптимизма и годы образования

Состояние	Причина	Функция	Баз. R^2	Нов. R^2	ΔR^2
Индекс кредитного оптимизма	Количество лет образования	log_shift	0,9173	0,9208	0,0035
Индекс кредитного оптимизма	Количество лет образования	sqrt_shift	0,9173	0,9207	0,0034
Индекс кредитного оптимизма	Количество лет образования	inv_shift	0,9173	0,9207	0,0034
Индекс кредитного оптимизма	Количество лет образования	z4	0,9173	0,9204	0,0031
Индекс кредитного оптимизма	Количество лет образования	log1p	0,9173	0,9204	0,0031
Индекс кредитного оптимизма	Количество лет образования	cbrt	0,9173	0,9204	0,0031
Индекс семьи	Среднегодовой доход, тыс. \$	z2	0,4727	0,4742	0,0015

Таблица 3. Лучшие одиночные нелинейные преобразования

В таблице 3 показаны лучшие одиночные преобразования, проверенные отдельно. Их индивидуальный прирост невелик, однако в совокупности банк функций оказался полезен для восстановления индекса кредитного оптимизма, что видно по таблице 2.




Рис. 5. Нелинейные зависимости причин и состояний с раскраской по сообществам

Отдельно были построены графики зависимостей с выделением одного сообщества красным цветом. Они показывают, что общественные причины задают положение сообщества как группы, а индивидуальные причины объясняют разброс респондентов внутри этой группы. Поэтому `community_id` является важным диагностическим признаком структуры данных, даже если его one-hot-представление не вошло в финальный классификатор.




Рис. 6. Пример зависимостей с выделением одного сообщества



Рис. 7. Различия среднего ранга счастья между сообществами

3.4. Качество классификации

Финальная проверка выполнялась на rowwise-разбиении с SEED = 7. Лучший воспроизводимый результат дала конфигурация:

`predicted states + vif-causes + sphere`, без `community one-hot`.

Итоговое значение `micro precision` равно 0,6063, что превышает требуемый порог 0,6. Так как задача является многоклассовой однометочной классификацией, `assurasy` имеет то же значение 0,6063.

Класс	Precision	Recall	F1	Support
Hopeless	0,74	0,79	0,76	53
Depressed	0,75	0,69	0,72	55
Suffering	0,44	0,39	0,41	70
Struggling	0,34	0,34	0,34	47
Coping	0,47	0,42	0,44	65
Just ok	0,55	0,60	0,57	52
Doing well	0,73	0,88	0,80	66
Blooming	0,67	0,74	0,71	39
Thriving	0,90	0,69	0,78	26
Prospering	0,67	1,00	0,80	2

Таблица 4. Отчет классификации для финальной модели




Рис. 8. Матрица ошибок классификатора

Матрица ошибок показывает, что основные ошибки возникают между соседними категориями: *Suffering*, *Struggling*, *Coping* и *Just ok*. Для упорядоченной шкалы счастья это ожидаемо: границы между средними классами менее резкие, чем между крайними состояниями.

3.5. Прогноз для unknown-наблюдений

После проверки финальная модель была обучена на всех 1900 known-наблюдениях и применена к 600 unknown-строкам. Для unknown сначала были восстановлены четыре состояния, затем по ним, причинам и сфере занятости был предсказан класс счастья.

Предсказанный класс	Количество
Suffering	107
Doing well	98
Hopeless	71
Just ok	66
Coping	63
Struggling	62
Depressed	59
Blooming	47
Thriving	24
Prospering	3

Таблица 5. Распределение прогнозов для unknown-наблюдений




Рис. 9. Распределение предсказанных классов для unknown

Заключение

В работе была построена двухэтапная модель прогноза ощущения счастья. Главная методологическая проблема состояла в том, что состояния отсутствуют для всех unknown-наблюдений. Поэтому вместо некорректного сценария реальные состояния $\rightarrow$ счастье использовалась схема причины $\rightarrow$ восстановленные состояния $\rightarrow$ счастье.

После VIF-фильтрации из причин были удалены два мультиколлинеарных общественных признака. По связи со счастьем и качеству восстановления были выбраны четыре состояния: социальная поддержка, технологический прогресс, кредитный оптимизм и продовольственная безопасность. Среднее качество их восстановления по OOF составило $R^2 = 0,9148$.

Нелинейные преобразования были полезны для восстановления состояний, особенно для индекса кредитного оптимизма. Как одиночные добавления они давали небольшой прирост, но банк преобразований позволил улучшить самое сложное из выбранных состояний. Графики по сообществам показали выраженную групповую структуру данных: сообщества отличаются по среднему уровню счастья и по областям значений общественных причин. При этом на выбранном rowwise-разбиении лучшая финальная модель использовала сферу занятости, но не использовала community one-hot.

Итоговая логистическая регрессия на предсказанных состояниях, причинах после VIF-фильтра и сфере занятости достигла **micro precision** = 0,6063. Требуемый порог 0,6 был преодолен. Полученный прогноз для 600 unknown-наблюдений сохранен в ноутбуке как результат финального обучения.

Список литературы

1. Гмурман, В. Е. Теория вероятностей и математическая статистика: учебное пособие. — Москва : Юрайт, 2014.
2. Документация библиотеки scikit-learn [Электронный ресурс]. — Режим доступа: <https://scikit-learn.org/>.
3. Документация библиотеки statsmodels [Электронный ресурс]. — Ре-

жим доступа: <https://www.statsmodels.org/>.

4. Документация библиотек NumPy, pandas, SciPy [Электронный ресурс].